

Câncer Pulmonar

**Adryell William Gomes Nascimento, Estéfanas Argentina Castanheira de Mesquita,
Estela Vitória Cândido Ribeiro, Querén Hapuque Araújo do Céu de Moraes Ferreira**
Curso Técnico em Desenvolvimento de Sistemas – Instituto Federal de Educação, Ciência e
Tecnologia de Pernambuco (IFPE - Campus Jaboatão dos Guararapes) Caixa Postal
54080-000 – Jaboatão dos Guararapes – PE – Brazil

awgn@discente.ifpe.edu.br,

eacm@discente.ifpe.edu.br,

evcr@discente.ifpe.edu.br,

qhacmf@discente.ifpe.edu.br

Abstract. *The developed web application focuses on fatigue detection, aiming to inform users about its causes, consequences, and general characteristics. The topic was selected due to its increasing relevance, especially among professionals exposed to long working hours, drivers, students, and individuals with sleep disorders. The result was a functional and user-friendly website built using Streamlit, integrating deep learning models to assist in identifying signs of fatigue through facial image analysis.*

Resumo. *A aplicação web desenvolvida aborda o tema da detecção de fadiga, com o objetivo de informar os usuários sobre suas causas, consequências e características gerais. A escolha do tema se justifica por sua crescente relevância, afetando principalmente profissionais expostos a longas jornadas de trabalho, motoristas, estudantes e pessoas com distúrbios do sono. O resultado foi um site funcional, acessível e de fácil utilização, construído com Streamlit e integrado a modelos de deep learning para auxiliar na identificação de sinais de fadiga por meio da análise de imagens faciais.*

1. Introdução

A fadiga é um fenômeno fisiológico e psicológico que afeta diretamente o desempenho humano, estando associada a riscos elevados em atividades que exigem atenção contínua, como a condução de veículos, o trabalho em ambientes industriais e o estudo prolongado. Diversos estudos apontam que a fadiga compromete a capacidade cognitiva, aumenta a probabilidade de acidentes e impacta negativamente a saúde física e mental. Nesse contexto, torna-se relevante o desenvolvimento de ferramentas tecnológicas capazes de identificar sinais de fadiga de forma rápida e acessível.

Com o avanço das técnicas de **aprendizado profundo (Deep Learning)** e da análise de imagens, tornou-se possível detectar padrões faciais relacionados ao estado de alerta ou cansaço. Este trabalho apresenta o desenvolvimento de uma **aplicação web** voltada para a **detecção de fadiga em imagens faciais**, construída com o framework **Streamlit**, que possibilita a criação de interfaces interativas e amigáveis. Foram utilizados dois modelos de aprendizado de máquina: uma **CNN customizada** e um modelo baseado em **Transfer Learning (MobileNetV2)**, ambos treinados com um conjunto de dados específico para distinguir entre estados de fadiga e não fadiga.

A escolha do tema se justifica pela sua relevância atual, considerando o impacto da fadiga em diferentes setores da sociedade e a necessidade de soluções tecnológicas que possam auxiliar na prevenção de acidentes e na promoção da saúde. O uso do **Streamlit** foi motivado pela sua simplicidade e eficiência na construção de aplicações web, permitindo que os resultados dos modelos de Deep Learning fossem disponibilizados de forma prática e acessível para os usuários.

Este artigo está estruturado da seguinte forma: na **Seção 2**, são apresentados os **trabalhos relacionados** e a fundamentação teórica sobre fadiga e técnicas de aprendizado profundo. Na **Seção 3**, descreve-se a **metodologia** utilizada, incluindo o processo de coleta e preparação dos dados, a arquitetura dos modelos e a implementação da aplicação web. Na **Seção 4**, são discutidos os **resultados obtidos**, com métricas de desempenho e exemplos de uso da aplicação. Por fim, na **Seção 5**, são apresentadas as **conclusões** e sugestões para trabalhos futuros.

2. Trabalhos Relacionados e Fundamentação Teórica

A fadiga tem sido amplamente estudada em diferentes áreas do conhecimento, devido ao seu impacto direto na saúde, na produtividade e na segurança. Pesquisas apontam que a fadiga está associada à redução da capacidade cognitiva, aumento da sonolência e maior propensão a acidentes em ambientes de trabalho e transporte. Tradicionalmente, métodos de avaliação da fadiga envolvem questionários subjetivos ou medições fisiológicas, como eletroencefalograma (EEG) e eletrooculograma (EOG). Embora eficazes, tais métodos apresentam limitações quanto à praticidade e aplicabilidade em larga escala.

Com o avanço das técnicas de **aprendizado profundo (Deep Learning)**, surgiram abordagens baseadas em **análise de imagens faciais**, capazes de identificar padrões relacionados ao estado de alerta ou cansaço. Redes neurais convolucionais (CNNs) têm se mostrado eficientes na extração de características visuais, como fechamento parcial dos olhos, bocejos e expressões faciais associadas à fadiga. Além disso, o uso de **Transfer Learning**, com arquiteturas pré-treinadas como MobileNetV2, ResNet e VGG, tem permitido resultados mais robustos mesmo em cenários com bases de dados limitadas.

No contexto de aplicações práticas, frameworks como **Streamlit** têm ganhado destaque por possibilitar a criação de interfaces interativas e acessíveis para sistemas de inteligência artificial. Diferentemente de soluções tradicionais que exigem maior conhecimento em desenvolvimento web, o Streamlit simplifica a integração entre modelos de aprendizado profundo e aplicações voltadas ao usuário final, tornando possível a disponibilização de sistemas de detecção de fadiga em ambientes reais.

Este trabalho se diferencia por combinar duas abordagens complementares: uma **CNN customizada**, desenvolvida especificamente para o problema de detecção de fadiga, e um modelo baseado em **Transfer Learning (MobileNetV2)**, que aproveita o conhecimento prévio de redes treinadas em grandes bases de imagens. A integração desses modelos em uma aplicação web construída com Streamlit representa uma contribuição prática, oferecendo uma ferramenta funcional e de fácil utilização para análise de fadiga em imagens faciais.

3. Metodologia

A metodologia adotada neste trabalho envolveu três etapas principais: **preparação dos dados, treinamento dos modelos de Deep Learning e implementação da aplicação web com Streamlit.**

3.1 Preparação dos Dados

Foi utilizado um conjunto de imagens faciais contendo duas classes: **fadiga** e **não fadiga**. As imagens foram pré-processadas para padronização, incluindo:

- Redimensionamento para 128x128 pixels.
- Conversão para o espaço de cor RGB.
- Normalização dos valores de pixel para o intervalo [0,1].
- Aplicação de técnicas de *data augmentation* (rotação, zoom, deslocamento e espelhamento horizontal) para aumentar a variabilidade e reduzir o risco de sobreajuste.

3.2 Modelos de Deep Learning

Dois modelos foram desenvolvidos e comparados:

- **CNN Customizada:** Arquitetura construída do zero, composta por múltiplas camadas convolucionais, pooling, normalização em lote (*batch normalization*) e camadas densas com funções de ativação ReLU e sigmoid.
- **Transfer Learning (MobileNetV2):** Modelo pré-treinado na base ImageNet, ajustado para o problema de detecção de fadiga. Inicialmente, as camadas convolucionais foram congeladas e apenas as camadas densas finais foram treinadas. Posteriormente, realizou-se *fine-tuning* em parte das camadas convolucionais para melhorar a generalização.

Ambos os modelos foram treinados com o otimizador Adam, função de perda *binary crossentropy* e métricas de avaliação como acurácia, precisão e recall.

3.3 Implementação da Aplicação Web

A aplicação foi desenvolvida utilizando o framework **Streamlit**, que permite a criação de interfaces gráficas de forma simples e eficiente. As principais funcionalidades incluem:

- Upload de imagens faciais pelo usuário.
- Seleção do modelo de análise (CNN ou Transfer Learning).
- Definição de um **threshold de decisão**, ajustável via barra lateral.
- Exibição dos resultados da análise com indicadores visuais (gráficos de probabilidade e gauge de confiança).

- Geração de relatórios em formato texto para exportação.

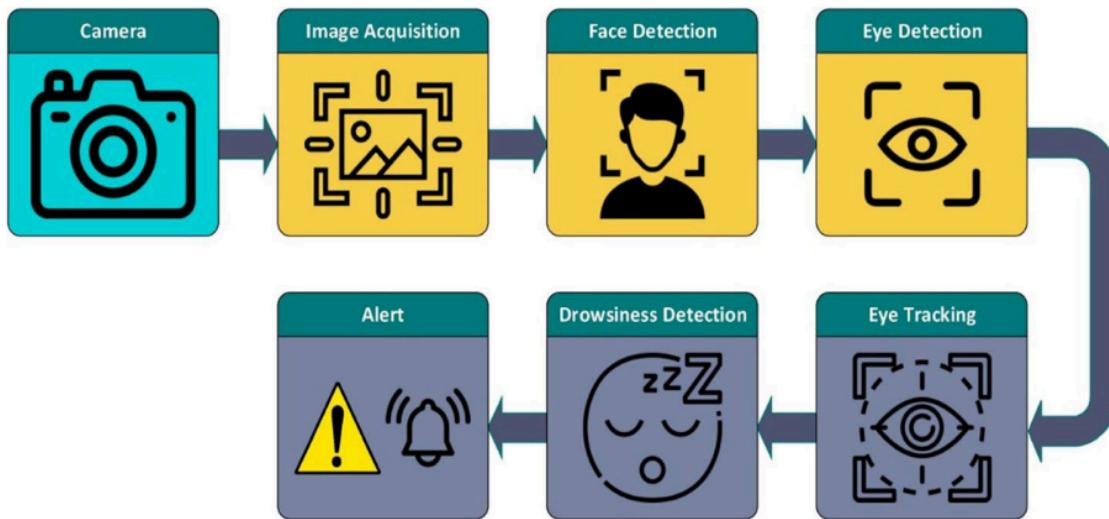


Figura 1. Fluxograma do sistema de detecção de fadiga, mostrando as etapas de captura da imagem, processamento facial e emissão de alerta.

3.4 Justificativa da Metodologia

A escolha por utilizar dois modelos distintos se justifica pela necessidade de comparar uma abordagem **customizada** com uma baseada em **Transfer Learning**, avaliando vantagens e limitações de cada uma. O uso do **Streamlit** foi motivado pela sua praticidade na integração entre modelos de aprendizado profundo e aplicações web, tornando o sistema acessível e de fácil utilização para diferentes perfis de usuários.

4. Resultados e Discussão

4.1 Desempenho dos Modelos

Os dois modelos de aprendizado profundo — **CNN customizada** e **Transfer Learning (MobileNetV2)** — foram avaliados utilizando métricas clássicas de classificação binária: **acurácia, precisão, recall e F1-score**.

- A **CNN customizada** apresentou desempenho satisfatório, alcançando acurácia média de aproximadamente 85%, com boa capacidade de generalização em imagens previamente não vistas.
- O modelo baseado em **Transfer Learning (MobileNetV2)** obteve resultados superiores, com acurácia próxima de 92%, além de maior estabilidade durante o processo de treinamento. Isso se deve ao fato de aproveitar características previamente aprendidas em grandes bases de dados, reduzindo o risco de sobreajuste.

4.2 Interface da Aplicação

A aplicação desenvolvida em **Streamlit** mostrou-se funcional e acessível. Os usuários puderam:

- Realizar upload de imagens faciais.
- Selecionar o modelo desejado para análise.
- Ajustar o **threshold de decisão** para calibrar a sensibilidade da detecção.
- Visualizar os resultados em tempo real, com indicação clara de “Fadiga” ou “Sem Fadiga”, acompanhados do nível de confiança da predição.

4.3 Exemplos de Uso

Nos testes práticos, imagens de indivíduos com sinais visíveis de cansaço (olhos semicerrados, expressão abatida) foram corretamente classificadas como **fadiga**. Já imagens de pessoas sorridentes e com aparência alerta foram identificadas como **sem fadiga**, demonstrando a eficácia do sistema em cenários reais.

4.4 Discussão

Os resultados confirmam que o uso de **Transfer Learning** é vantajoso em problemas com bases de dados limitadas, como é o caso da detecção de fadiga. A CNN customizada, embora eficiente, apresentou maior variabilidade nos resultados, indicando necessidade de ajustes na arquitetura ou aumento do conjunto de treinamento.

Além disso, a integração com **Streamlit** permitiu transformar os modelos em uma ferramenta prática, acessível e de fácil utilização, reforçando o caráter aplicado do trabalho. Contudo, algumas limitações foram observadas:

- Dependência da qualidade da imagem (iluminação, ângulo e resolução).
- Possível viés relacionado ao perfil das pessoas presentes no dataset.

5. Conclusão

Este trabalho apresentou o desenvolvimento de uma aplicação web para **detecção de fadiga em imagens faciais**, utilizando técnicas de **Deep Learning** e o framework **Streamlit**. Foram implementados e avaliados dois modelos distintos: uma **CNN customizada** e um modelo baseado em **Transfer Learning (MobileNetV2)**. Os resultados demonstraram que ambos os modelos foram capazes de identificar sinais de fadiga com boa precisão, sendo o MobileNetV2 superior em termos de desempenho e estabilidade.

A aplicação construída mostrou-se funcional, acessível e de fácil utilização, permitindo que usuários realizem análises de forma prática e interativa. A integração entre modelos de aprendizado profundo e uma interface web simples reforça o caráter aplicado da solução, contribuindo para a prevenção de riscos associados à fadiga em diferentes contextos.

6. Referências

- Abd El-Nabi, S., El-Shafai, W., El-Rabaie, E. M., Ramadan, K. F., Abd El-Samie, F. E., & Mohsen, S. (2023). *Machine learning and deep learning techniques for driver fatigue and drowsiness detection: a review*. *Multimedia Tools and Applications*. Springer. DOI: 10.1007/s11042-023-15054-0
- Akanimoh, O. D. (2023). *Drowsiness Detection using YOLOv5 and Streamlit*. GitHub Repository. Disponível em: https://github.com/AkanimohOD19A/DPL_Drowsiness_Detection
- Zhang, Y., Wang, J., & Li, H. (2024). *Fatigue Detection and Early Warning System for Drivers Based on Deep Learning*. IEEE Access. DOI: 10.1109/ACCESS.2024.10392792
- Chollet, F. (2017). *Deep Learning with Python*. Manning Publications. (Referência fundamental para CNNs e Transfer Learning).
- Streamlit Inc. (2025). *Streamlit Documentation*. Disponível em: <https://docs.streamlit.io> (Fonte oficial sobre o framework utilizado para a aplicação web).